Università degli Studi di Napoli
Federico II
Dipartimento di Ingegneria Elettrica e delle Tecnologie dell'Informazione

Statistical Learning and Data Analysis – Module A

CONFIDENCE INTERVALS

Prof. Emiliano del Gobbo
emiliano.delgobbo@unina.it

1

Inverence for the mean of two normal populations

The random variable representing the difference between the means of two independent samples, C_1 and C_2 **,drawn from the normal populations** P_1 **and** P_2 **,is normally distributed with mean and variance**

given:

$$E(\overline{X}_1 - \overline{X}_2) = \mu_1 - \mu_2, \quad \sigma^2_{\overline{X}_1 - \overline{X}_2} = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}.$$

The ratio

$$Z_{\overline{X}_1 - \overline{X}_2} = \frac{(\overline{X}_1 - \overline{X}_2) - (\mu_1 - \mu_2)}{\sigma_{\overline{X}_1 - \overline{X}_2}}$$

It is a standard normal random variable.

© Emiliano del Gobbo

2

Distribution of the random variable representing the difference between two means

Under the assumption of population normality, the random variable $\overline{X}_1 - \overline{X}_2$ is a linear combination of two independent normal random variables with $a_1 = 1$ and $a_2 = -1$ coefficients, and is therefore normally distributed.

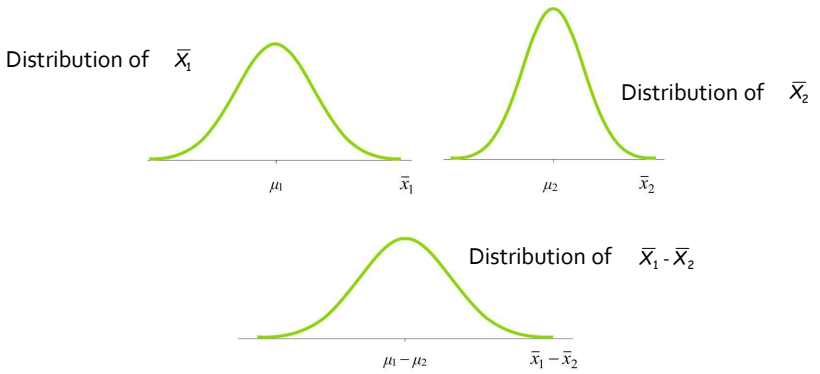

Confidence interval for the difference between two means — normal populations (known variances)

For the construction of a confidence interval, it is natural to employ the estimator $D = \overline{X}_1 - \overline{X}_2$. Then

$$P\left[-z_{1-\alpha/2} < \frac{(\overline{X}_1 - \overline{X}_2) - (\mu_1 - \mu_2)}{\sigma_{\overline{X}_1 - \overline{X}_2}} < z_{1-\alpha/2}\right] = 1 - \alpha,$$

therefore

$$P[(\overline{X}_1 - \overline{X}_2) - z_{1-\alpha/2}\sigma_{\overline{X}_1 - \overline{X}_2} < \mu_1 - \mu_2 < (\overline{X}_1 - \overline{X}_2) + z_{1-\alpha/2}\sigma_{\overline{X}_1 - \overline{X}_2}] = 1 - \alpha.$$

Limits of the confidence interval

$$l_1 = (\overline{x}_1 - \overline{x}_2) - z_{1-\alpha/2}\sigma_{\overline{X}_1 - \overline{X}_2}$$

$$l_2 = (\overline{x}_1 - \overline{x}_2) + z_{1\ \alpha/2}\sigma_{\overline{X}_1 - \overline{X}_2}$$

Example 1 — Confidence interval for the difference between two means — normal populations (known variances)

- Following a study on the metabolizable energy content (in kcal per gram) of two different types of cat food, the results shown in the table were obtained:

Sample	Sample size	Sample mean
Food type A	29	1,54
Food type B	28	1,19

Assuming that the variances of the two populations are 0.103 and 0.074, determine the 95% confidence interval for the difference between the means.

© Emiliano del Gobbo

Example 1 (continued)

$$\sigma^2_{\overline{X}_1-\overline{X}_2} = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2} = \frac{0{,}103}{29} + \frac{0{,}074}{28} = 0{,}0062;$$

$$l_1 = (\overline{x}_1 - \overline{x}_2) - z_{1-\alpha/2}\sigma_{\overline{X}_1-\overline{X}_2} = (1{,}54 - 1{,}19) - 1{,}96\sqrt{0{,}0062} = 0{,}196;$$

$$l_2 = (\overline{x}_1 - \overline{x}_2) + z_{1-\alpha/2}\sigma_{\overline{X}_1-\overline{X}_2} = (1{,}54 - 1{,}19) + 1{,}96\sqrt{0{,}0062} = 0{,}504.$$

The difference between the **average nutritional capacity** of the two cat foods is **positive** and is likely to lie within the interval **(0.196, 0.504)**.

© Emiliano del Gobbo

Test for the difference between two means: normal populations (known variances)

For $H_0 : \delta = \mu_1 - \mu_2 = 0$

The alternative hypothesis may take one of the following three forms:

$$\left.\begin{array}{l} H_1 : \delta < 0 \\ H_1 : \delta > 0 \end{array}\right\}$$

One-tailed alternative hypothesis

$$H_1 : \delta \neq 0$$

Bidirectional alternative hypothesis

© Emiliano del Gobbo

Test for the difference between two means – normal populations (known variances)

If the null hypothesis is true, the expected value of the $D = \overline{X}_1 - \overline{X}_2$ difference is null:

$$E(\overline{X}_1 - \overline{X}_2) = E(\overline{X}_1) - E(\overline{X}_2) = \mu_1 - \mu_2 = 0.$$

$$Z_{\overline{X}_1 - \overline{X}_2} = \frac{\overline{X}_1 - \overline{X}_2}{\sigma_{\overline{X}_1 - \overline{X}_2}}$$

The sample statistic follows a standard normal distribution, N(0, 1).

© Emiliano del Gobbo

Hypothesis systems and rejection regions for the test on the difference between two means (known variances)

Hypothesis H_0	Hypothesis H_1	Test statistic	Rejection area R
$\delta = \mu_1 - \mu_2 = 0$	$\delta = \mu_1 - \mu_2 < 0$	$Z_{\bar{X}_1 - \bar{X}_2} = \dfrac{\bar{X}_1 - \bar{X}_2}{\sigma_{\bar{X}_1 - \bar{X}_2}}$	$\{z_{\bar{x}_1 - \bar{x}_2} : z_{\bar{x}_1 - \bar{x}_2} < -z_{1-\alpha}\}$
	$\delta = \mu_1 - \mu_2 > 0$		$\{z_{\bar{x}_1 - \bar{x}_2} : z_{\bar{x}_1 - \bar{x}_2} > z_{1-\alpha}\}$
	$\delta = \mu_1 - \mu_2 \neq 0$		$\{z_{\bar{x}_1 - \bar{x}_2} : \lvert z_{\bar{x}_1 - \bar{x}_2} \rvert > z_{1-\alpha/2}\}$

The logic underlying these decision rules is that **very large (or very small) values of the test statistic** $Z_{\bar{X}_1 - \bar{X}_2}$ **are unlikely to occur by chance,** but rather indicate that the mean of the first population is higher (or lower) than that of the second, as stated in the alternative hypothesis.

Test for the difference between two means – normal populations (known variances) Conclusion

Using the same data as in *Example 1*, test whether the two types of cat food have the same mean metabolizable energy content against the alternative that Food A has a higher mean value. Let $\alpha = 0{,}05$.

Test statistic: $Z_{\bar{X}_1 - \bar{X}_2} = \dfrac{\bar{X}_1 - \bar{X}_2}{\sigma_{\bar{X}_1 - \bar{X}_2}}$;

Rejection region: $\{z_{\bar{x}_1 - \bar{x}_2} : z_{\bar{x}_1 - \bar{x}_2} > z_{0,95} = 1{,}645\}$;

Observed value of the test statistic:

$$z_{\bar{x}_1 - \bar{x}_2} = \frac{\bar{x}_1 - \bar{x}_2}{\sigma_{\bar{X}_1 - \bar{X}_2}} = \frac{0{,}35}{\sqrt{0{,}0062}} = 4{,}445;$$

Example 2 – Test for the difference between two means – normal populations (known variances)

Conclusion: Since the value of the test statistic falls within the rejection region, the null hypothesis is rejected. In other words, the data provide sufficient evidence to reject the null hypothesis.

© Emiliano del Gobbo

Observed significance level

Let, for example, H_1 : $\delta = \mu_1 - \mu_2 > 0$

Difference between the sample means

$$\alpha_{oss} = P\left(Z_{\bar{X}_1 - \bar{X}_2} > \frac{\bar{x}_1 - \bar{x}_2}{\sigma_{\bar{X}_1 - \bar{X}_2}} \middle| \delta = 0\right)$$

The null hypothesis is rejected if the observed significance level (p-value) is smaller than the predetermined significance level α

© Emiliano del Gobbo

Example 3 – Observed level of significance

Repeat the hypothesis test from the previous example using the observed significance level.

Test statistics: $Z_{\bar{X}_1-\bar{X}_2} = \dfrac{\bar{X}_1 - \bar{X}_2}{\sigma_{\bar{X}_1-\bar{X}_2}}$;

Observed value of the test statistic:

$$z_{\bar{x}_1-\bar{x}_2} = \frac{\bar{x}_1 - \bar{x}_2}{\sigma_{\bar{X}_1-\bar{X}_2}} = \frac{0{,}35}{\sqrt{0{,}0062}} = 4{,}445;$$

Observed significance level:

$$\alpha_{oss} = P\left(Z_{\bar{X}_1-\bar{X}_2} > 4{,}445 \mid \delta = 0\right) = 0{,}0000044;$$

© Emiliano del Gobbo

Example 3 – Observed level of significance (II)

Conclusion: Since the observed significance level is lower than 0.05, the null hypothesis is rejected. In other words, the data provide sufficient evidence to reject the null hypothesis.

© Emiliano del Gobbo

Inference on Two Means: Small Samples and Equal Variances

Let $\mathcal{C}_1$ and $\mathcal{C}_2$ be two samples drawn from normal populations $\mathcal{P}_1$ and $\mathcal{P}_2$ with means μ_1 and μ_2 and **unknown but equal variances**, then:

$$T_{\bar{X}_1-\bar{X}_2} = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{S_c\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}}$$

- it follows a **Student's t distribution** with $n_1 + n_2 - 2$ degrees of freedom.

$$S_c^2 = \frac{S_1^2(n_1-1)+S_2^2(n_2-1)}{(n_1+n_2-2)}$$

© Emiliano del Gobbo

Confidence Interval for the Difference Between Two Means – Small Samples

$$P\left[-t_{1-\alpha/2} < \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{S_c\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}} < t_{1-\alpha/2}\right] = 1 - \alpha$$

Quantile of level $1-\alpha/2$ of the Student's t distribution with $n_1 + n_2 - 2$ degrees of freedom

We can indicate

estremi dell'intervallo di confidenza

$$l_1 = (\bar{x}_1 - \bar{x}_2) - t_{1-\alpha/2}s_c\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}$$

$$l_2 = (\bar{x}_1 - \bar{x}_2) + t_{1-\alpha/2}s_c\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}$$

© Emiliano del Gobbo

Esempio 4 - Intervallo di conf. per la differenza di due medie – piccoli campioni

È stato condotto uno studio per comprendere come la somministrazione di un ormone della crescita influisca sul peso dei ratti in stato di gravidanza, osservando l'aumento di peso durante la gestazione su 15 ratti trattati con l'ormone e su altrettanti ratti non trattati. I dati sono esposti nella tabella:

Si determini l'intervallo di confidenza al 99% per la differenza tra le medie delle due popolazioni.

Trattamento con ormone	Ampiezza campionaria	Media campionaria	Varianza campionaria
Assente	15	49,5	124,6
Presente	15	65,3	138,7

© Emiliano del Gobbo

Esempio 4 (*continuazione*)

$$s_c^2 = \frac{s_1^2 \times (n_1 - 1) + s_2^2 \times (n_2 - 1)}{n_1 + n_2 - 2} = \frac{124{,}6 \times 14 + 138{,}7 \times 14}{28} = 131{,}65;$$

$$l_1 = (49{,}5 - 65{,}3) - 2{,}763\sqrt{131{,}65(1/15 + 1/15)} = -27{,}38;$$

$$l_2 = (49{,}5 - 65{,}3) + 2{,}763\sqrt{131{,}65(1/15 + 1/15)} = -4{,}22.$$

<u>Conclusione</u>: la differenza tra le medie delle due popolazioni di interesse è negativa e verosimilmente compresa nell'intervallo (-27,38, -4,22).

© Emiliano del Gobbo

Test per la differenza di due medie: piccoli campioni e varianze uguali

$$H_0 : \delta = \mu_1 - \mu_2 = 0 \text{ e } H_1 : \delta > 0$$

statistica test da impiegare per la verifica dell'ipotesi

$$T_{\overline{X}_1 - \overline{X}_2} = \frac{\overline{X}_1 - \overline{X}_2}{S_c \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

$$R = \{ t_{\overline{x}_1 - \overline{x}_2} : t_{\overline{x}_1 - \overline{x}_2} > t_{1-\alpha} \}$$

Zona di rifiuto del test

$$t_{\overline{x}_1 - \overline{x}_2} = \frac{\overline{x}_1 - \overline{x}_2}{s_c \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

Zone di rifiuto del test per i diversi sistemi di ipotesi

Ipotesi H_0	Ipotesi H_1	Statistica test	Zona di rifiuto R
$\mu = \mu_0$	$\mu < \mu_0$	$T_{\overline{X}_2 - \overline{X}_1} = \frac{\overline{X}_1 - \overline{X}_2}{S_c \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$	$\{ t_{\overline{x}_1 - \overline{x}_2} : t_{\overline{x}_1 - \overline{x}_2} < -t_{1-\alpha} \}$
	$\mu > \mu_0$		$\{ t_{\overline{x}_1 - \overline{x}_2} : t_{\overline{x}_1 - \overline{x}_2} > t_{1-\alpha} \}$
	$\mu \neq \mu_0$		$\{ t_{\overline{x}_1 - \overline{x}_2} : \lvert t_{\overline{x}_1 - \overline{x}_2} \rvert > t_{1-\alpha/2} \}$

$t_{1-\alpha}$ e $t_{1-\alpha/2}$ **sono i quantili di livello $1-\alpha$ e $1-\alpha/2$** della distribuzione t di Student con $n_1 + n_2 - 2$ **gradi di libertà**

Esempio 5 - Test per la differenza di due medie - piccoli campioni e varianze uguali

Con gli stessi dati dell'Esempio 4, si stabilisca se l'accrescimento ponderale medio dei ratti trattati con l'ormone è significativamente superiore a quello dei ratti non trattati. Si ponga $\alpha = 0{,}01$.

Sistema di ipotesi: $H_0 : \delta = \mu_1 - \mu_2 = 0; H_1 : \delta = \mu_1 - \mu_2 < 0;$

Statistica test: $T_{\overline{X}_1 - \overline{X}_2} = \dfrac{\overline{X}_1 - \overline{X}_2}{S_c\sqrt{1/n_1 + 1/n_2}};$

Zona di rifiuto: $\{t_{\overline{x}_1 - \overline{x}_2} : t_{\overline{x}_1 - \overline{x}_2} < -t_{0,99} = -2{,}467\};$

© Emiliano del Gobbo

Esempio 5 (*continuazione*)

Valore assunto dalla statistica test:

$$t_{\overline{x}_1 - \overline{x}_2} = \frac{\overline{x}_1 - \overline{x}_2}{s_c\sqrt{\dfrac{1}{n_1} + \dfrac{1}{n_2}}} = \frac{49{,}5 - 65{,}3}{\sqrt{131{,}65(1/15 + 1/15)}} = -3{,}771.$$

<u>Conclusione</u>: poiché il valore assunto dalla statistica test ricade nella zona di rifiuto, l'ipotesi nulla viene rigettata. In altri termini, l'accrescimento ponderale dei ratti trattati è significativamente superiore rispetto a quello dei non trattati.

© Emiliano del Gobbo

Inferenza sulla differenza di due medie: piccoli campioni e varianze non assunte uguali

statistica test da impiegare per la verifica dell'ipotesi

$$T'_{\bar{X}_1-\bar{X}_2} = \frac{(\bar{X}_1-\bar{X}_2)-(\mu_1-\mu_2)}{\sqrt{\frac{S_1^2}{n_1}+\frac{S_2^2}{n_2}}}$$

che ha distribuzione approssimativamente *t* di Student con un numero di gradi di libertà dato da

$$v = \frac{(a+b)^2}{a^2/(n_1-1)+b^2/(n_2-1)},$$

dove $a = s_1^2/n_1$ e $b = s_2^2/n_2$.

Inferenza sulla differenza di due medie: grandi campioni

La disponibilità di campioni con numerosità elevata consente di effettuare un'inferenza che ha validità generale.

$$Z_{\bar{X}_1-\bar{X}_2} = \frac{(\bar{X}_1-\bar{X}_2)-(\mu_1-\mu_2)}{\hat{\sigma}_{\bar{X}_1-\bar{X}_2}}$$

ha distribuzione prossima alla N(0,1)

$$\hat{\sigma}_{\bar{X}_1-\bar{X}_2} = \sqrt{\frac{S_1^2}{n_1}+\frac{S_2^2}{n_2}}$$

Limiti intervallo di confidenza

$$l_1 = (\bar{x}_1-\bar{x}_2) - z_{1-\alpha/2}\hat{\sigma}_{\bar{X}_1-\bar{X}_2}$$

$$l_2 = (\bar{x}_1-\bar{x}_2) + z_{1-\alpha/2}\hat{\sigma}_{\bar{X}_1-\bar{X}_2}$$

Ipotesi H_0	Ipotesi H_1	Statistica test	Zona di rifiuto R
$\mu_1-\mu_2=0$	$\mu_1-\mu_2<0$	$Z_{\bar{X}_1-\bar{X}_2} = \frac{\bar{X}_1-\bar{X}_2}{\hat{\sigma}_{\bar{X}_1-\bar{X}_2}}$	$\{z_{\bar{X}_1-\bar{X}_2}: z_{\bar{X}_1-\bar{X}_2} < -z_{1-\alpha}\}$
	$\mu_1-\mu_2>0$		$\{z_{\bar{X}_1-\bar{X}_2}: z_{\bar{X}_1-\bar{X}_2} > z_{1-\alpha}\}$
	$\mu_1-\mu_2\neq 0$		$\{z_{\bar{X}_1-\bar{X}_2}: \lvert z_{\bar{X}_1-\bar{X}_2}\rvert > z_{1-\alpha/2}\}$

Esempio 6 - Intervallo di conf. per la differenza di due medie – piccoli campioni

Per studiare l'effetto della presenza di pesce nella dieta alimentare sul livello di colesterolo, furono osservati, per un congruo periodo di tempo, due campioni di individui, il primo costituito da non consumatori di pesce e il secondo da consumatori di almeno 45 grammi di pesce al giorno. I dati sono riportati nella tabella che segue:

Consumo di pesce	Ampiezza campionaria	Livello medio colesterolo	Varianza campionaria
Assente	159	91,2	82,5
Presente	79	81,4	68,7

Si determini l'intervallo di confidenza al 90% per la differenza tra le medie delle due popolazioni.

© Emiliano del Gobbo

Esempio 6 (*continuazione*)

$$\frac{\alpha}{2} = \frac{1-0{,}90}{2} = 0{,}05;\ z_{1-\alpha/2} = z_{0{,}95} = 1{,}645;$$

$$l_1 = (91{,}2 - 81{,}4) - 1{,}645\sqrt{\frac{82{,}5}{159} + \frac{68{,}7}{79}} = 7{,}86;$$

$$l_2 = (91{,}2 - 81{,}4) + 1{,}645\sqrt{\frac{82{,}5}{159} + \frac{68{,}7}{79}} = 11{,}74.$$

<u>Conclusione</u>: la differenza tra le medie del colesterolo delle due popolazioni di interesse è positiva e verosimilmente compresa nell'intervallo (7,86, 11,74).

© Emiliano del Gobbo

Esempio 7 - Test per la differenza di due medie - grandi campioni

Sistema di ipotesi:

Con gli stessi dati dell'Esempio 6, si stabilisca se il livello medio del colesterolo nei consumatori di pesce è significativamente inferiore rispetto a quello dei non consumatori. Si ponga α=0,05.

$$H_0 : \delta = \mu_1 - \mu_2 = 0; H_0 : \delta = \mu_1 - \mu_2 > 0;$$

Statistica test: $$Z_{\overline{X}_1 - \overline{X}_2} = \frac{\overline{X}_1 - \overline{X}_2}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}};$$

Zona di rifiuto: $$\{z_{\overline{x}_1 - \overline{x}_2} : z_{\overline{x}_1 - \overline{x}_2} > z_{0,95} = 1,645\};$$

Esempio 7 (*continuazione*)

Valore assunto dalla statistica test:

$$z_{\overline{x}_1 - \overline{x}_2} = \frac{\overline{x}_1 - \overline{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} = \frac{91,2 - 81,4}{\sqrt{\frac{82,5}{159} + \frac{68,7}{79}}} = 8,32.$$

<u>Conclusione</u>: poiché il valore assunto dalla statistica test appartiene alla zona di rifiuto, l'ipotesi nulla viene rigettata. In altri termini, il colesterolo medio nei consumatori di pesce è significativamente maggiore che non tra i non consumatori.

Intervallo di confidenza per la differenza di due proporzioni (grandi campioni)

- Proporzioni delle due popolazioni: p_1 e p_2;
- Proporzione dei due campioni: $\hat{p}_1$ e $\hat{p}_2$;
- Varianza di $\hat{p}_1 - \hat{p}_2$: $\sigma^2_{\hat{p}_1-\hat{p}_2} = p_1(1-p_1)/n_1 + p_2(1-p_2)/n_2$.

Prendiamo la v.c.

$$Z_{\hat{p}_1-\hat{p}_2} = \frac{(\hat{p}_1-\hat{p}_2)-(p_1-p_2)}{\hat{\sigma}_{\hat{p}_1-\hat{p}_2}}$$

con

$$\hat{\sigma}_{\hat{p}_1-\hat{p}_2} = \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$$

la cui distribuzione è prossima alla normale N(0, 1), perché i campioni hanno grandi dimensioni.

Intervallo di confidenza per la differenza di due proporzioni (grandi campioni)

Dalla proposizione

$$P\left[-z_{1-\alpha/2} < \frac{(\hat{p}_1-\hat{p}_2)-(p_1-p_2)}{\sigma_{\hat{p}_1-\hat{p}_2}} < z_{1-\alpha/2}\right] \approx 1-\alpha$$

con l'usuale procedimento, si ottengono gli estremi dell'intervallo di confidenza per $p_1 - p_2$:

$$l_1 = (\hat{p}_1 - \hat{p}_2) - z_{1-\alpha/2}\hat{\sigma}_{\hat{p}_1-\hat{p}_2}$$
$$l_2 = (\hat{p}_1 - \hat{p}_2) + z_{1-\alpha/2}\hat{\sigma}_{\hat{p}_1-\hat{p}_2}$$

Esempio 8 - Intervallo di conf. per la differenza di due proporzioni – grandi campioni

In uno **studio sulla diffusione del lavoro a tempo parziale tra gli studenti, il preside di una facoltà universitaria fa effettuare un'indagine campionaria. Di seguito sono riportati i risultati distintamente per sesso:**

Lavoro a tempo parziale	Maschi	Femmine
Sì	235	127
No	1.150	683

Si determini l'intervallo di confidenza al 95% per la differenza delle proporzioni di studenti lavoratori tra i maschi e le femmine.

© Emiliano del Gobbo

Esempio 8 (*continuazione*)

$$\frac{\alpha}{2} = \frac{1-0{,}95}{2} = 0{,}025;\ z_{1-\alpha/2} = z_{0{,}975} = 1{,}96;$$

Proporzioni campionarie: $\hat{p}_1 = \frac{127}{810} = 0{,}157;\ \hat{p}_2 = \frac{235}{1.385} = 0{,}170;$

Estremi dell'intervallo di confidenza:

$$l_1 = (0{,}157 - 0{,}170) - 1{,}96\sqrt{\frac{0{,}157 \times 0{,}843}{810} + \frac{0{,}170 \times 0{,}830}{1.385}} = -0{,}045;$$

$$l_2 = (0{,}157 - 0{,}170) + 1{,}96\sqrt{\frac{0{,}157 \times 0{,}843}{810} + \frac{0{,}170 \times 0{,}830}{1.385}} = 0{,}019;$$

<u>Conclusione</u>: la differenza delle proporzioni di lavoratori a tempo parziale tra gli studenti e le studentesse è verosimilmente compresa nell'intervallo (-0,045, 0,019).

© Emiliano del Gobbo

Test per la differenza di due proporzioni - grandi campioni

Statistica test

$$Z_{\hat{p}_1-\hat{p}_2} = \frac{\hat{p}_1 - \hat{p}_2}{\hat{\sigma}_{\hat{p}_1-\hat{p}_2}}$$

$$\hat{\sigma}^2_{\hat{p}_1-\hat{p}_2} = \hat{p}_c(1-\hat{p}_c)\left(\frac{1}{n_1}+\frac{1}{n_2}\right)$$

dove

$$\hat{p}_c = \frac{\hat{p}_1 \cdot n_1 + \hat{p}_2 \cdot n_2}{n_1 + n_2}$$

Ipotesi H_0	Ipotesi H_1	Statistica test	Zona di rifiuto R
$p_1 - p_2 = 0$	$p_1 - p_2 < 0$	$Z_{\hat{p}_2-\hat{p}_1} = \frac{\hat{p}_1 - \hat{p}_2}{\hat{\sigma}_{\hat{p}_1-\hat{p}_2}}$	$\{z_{\hat{p}_1-\hat{p}_2} : z_{\hat{p}_1-\hat{p}_2} < -z_{1-\alpha}\}$
	$p_1 - p_2 > 0$		$\{z_{\hat{p}_1-\hat{p}_2} : z_{\hat{p}_1-\hat{p}_2} > z_{1-\alpha}\}$
	$p_1 - p_2 \neq 0$		$\{z_{\hat{p}_1-\hat{p}_2} : \lvert z_{\hat{p}_1-\hat{p}_2} \rvert > z_{1-\alpha/2}\}$

© Emiliano del Gobbo

Esempio 9 - Test per la differenza tra due proporzioni - grandi campioni

Con gli stessi dati dell'Esempio 8, si stabilisca se proporzione di studenti universitari che lavorano sia la stessa tra i maschi e le femmine, contro l'alternativa che siano diverse. Si ponga α=0,05.

Sistema di ipotesi: $H_0 : \delta = p_1 - p_2 = 0; H_1 : \delta = p_1 - p_2 \neq 0;$

Statistica test: $$Z_{\hat{p}_1-\hat{p}_2} = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}_c(1-\hat{p}_c)\left(\frac{1}{n_1}+\frac{1}{n_2}\right)}};$$

Zona di rifiuto: $\{z_{\hat{p}_1-\hat{p}_2} : z_{\hat{p}_1-\hat{p}_2} \notin (-1{,}96, 1{,}96)\};$

© Emiliano del Gobbo

Esempio 9 (*continuazione*)

Stima del parametro *p* sotto H_0:

$$\hat{p}_c = \frac{\hat{p}_1 \cdot n_1 + \hat{p}_2 \cdot n_2}{n_1 + n_2} = \frac{0{,}157 \times 810 + 0{,}170 \times 1.385}{810 + 1.385} = 0{,}165;$$

Valore assunto dalla statistica test:

$$z_{\hat{p}_1 - \hat{p}_2} = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}_c(1-\hat{p}_c)\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} = \frac{0{,}157 - 0{,}170}{\sqrt{0{,}165 \times 0{,}835\left(\frac{1}{810} + \frac{1}{1.385}\right)}} = -0{,}792;$$

<u>Conclusione</u>: poiché il valore assunto dalla statistica test non cade nella zona di rifiuto, l'ipotesi nulla non viene rifiutata. In altri termini, non vi sono evidenze sufficienti per escludere che la proporzione di studenti che lavorano sia uguale tra i maschi e tra le femmine.

Distribuzione di probabilità *F* di Fisher

Siano X_1 e X_2 due variabili casuali indipendenti aventi distribuzioni di probabilità chi-quadrato con r_1 e r_2 gradi di libertà. Allora, la distribuzione di probabilità del rapporto

$$\boxed{y = \frac{X_1/r_1}{X_2/r_2}}$$

è v.c. con la seguente funzione di densità

$$f(y) = c y^{\frac{r_1}{2}-1}\left(1 + \frac{r_1}{r_2} y\right)^{-\frac{r_1+r_2}{2}}, \quad 0 \le y < +\infty,$$

dove c è una costante positiva, mentre r_1 e r_2 sono numeri interi, detti **gradi di libertà**: Tale v.c. è nota come *F* di Fisher.

Distribuzione di probabilità *F* di Fisher

Distribuzione di probabilità *F* di Fisher

Funzione di densità *F* di Fisher per $r_1 = 10$ e alcuni valori di r_2

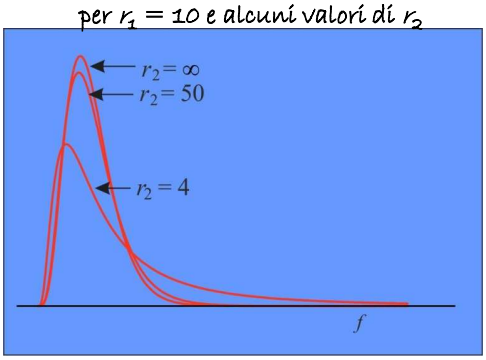

Quantile

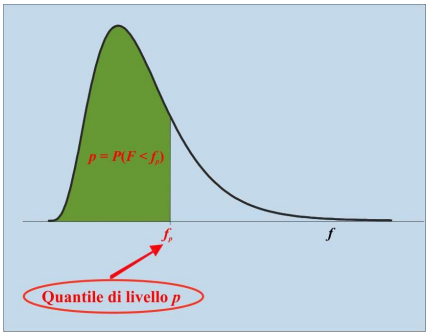

Test per le varianze di due popolazioni normali

Siano C_1 e C_2 due campioni indipendenti provenienti dalle popolazioni normali $\mathcal{P}_1$ e $\mathcal{P}_2$ aventi la stessa varianza. Siano S_1^2 e S_2^2 le varianze del primo e del secondo campione. Allora, il rapporto

$$\boxed{F = \frac{S_1^2}{S_2^2}}$$

ha distribuzione *F* di Fisher con $n_1 - 1$ e $n_2 - 1$ gradi di libertà.

Test per le varianze di due popolazioni normali

Il rapporto

$$F = \frac{S_1^2}{S_2^2}$$

è una appropriata statistica campionaria per sottoporre a verifica l'ipotesi di uguaglianza delle varianze di due popolazioni normali $\mathcal{P}_1$ e $\mathcal{P}_2$. Se σ_2^2 è la varianza di

$\mathcal{P}_1$ e σ_1^2 è la varianza di $\mathcal{P}_2$, le zone di rifiuto del test per la verifica dell'ipotesi nulla

$$H_0 : \sigma_1^2 = \sigma_2^2$$

Sono quelle indicate nella tabella che segue.

Test per le varianze di due popolazioni normali

Ipotesi H_0	Ipotesi H_1	Statistica test	Zona di rifiuto R
$\sigma_1^2 = \sigma_2^2$	$\sigma_1^2 < \sigma_2^2$	$F = \frac{S_1^2}{S_2^2}$	$\{f : f < f_\alpha\}$
	$\sigma_1^2 > \sigma_2^2$		$\{f : f > f_{1-\alpha}\}$
	$\sigma_1^2 \neq \sigma_2^2$		$\{f : f \notin (f_{\alpha/2}, f_{1-\alpha/2})\}$

f è il valore osservato della v.c. F, f_α, $f_{1-\alpha}$, $f_{\alpha/2}$ e $f_{1-\alpha/2}$ **sono i quantili di vario livello** della distribuzione di probabilità della stessa v.c.

Esempio 10 - Test per le varianze di due popolazioni normali

In un'industria alimentare, vengono utilizzate due tipi di confezionatrici, A e B. Il dubbio è che le confezioni realizzate con la macchina A presentino una variabilità più elevata.
Per dirimere questo dubbio, vengono osservati i pesi in grammi di due campioni casuali di confezioni (da 500 g) di uno stesso tipo di pasta. I dati sono riportati di seguito:

Confezionatrice	Ampiezza campionaria	Deviazione standard campionaria
A	31	7,08
B	28	4,31

Si sottoponga a verifica l'ipotesi che le due macchine si equivalgono quanto alla variabilità dei pesi delle confezioni realizzate. Si ponga α=0,05.

© Emiliano del Gobbo

Esempio 10 (*continuazione*)

Sistema di ipotesi: $H_0 : \sigma_1^2 = \sigma_2^2;\ H_1 : \sigma_1^2 > \sigma_2^2;$

Statistica test: $F = \dfrac{S_1^2}{S_2^2};$

Zona di rifiuto: $\{f : f > f_{0,95} = 1{,}884\};$

Valore assunto dalla statistica test: $f = \dfrac{S_1^2}{S_2^2} = \dfrac{7{,}08^2}{4{,}31^2} = 2{,}698.$

<u>Conclusione</u>: poiché il valore assunto dalla statistica test cade nella zona di rifiuto, l'ipotesi nulla viene rifiutata. In altri termini, vi sono evidenze sufficienti per concludere che la variabilità dei pesi delle confezioni realizzate con la confezionatrice A è più forte.

© Emiliano del Gobbo